



Trabajo de:

Análisis y minería sobre un libro del recurso Project Gutenberg

Presentado por:

Wilson otero

Alexander chiquillo

Presentado a:

Prof. Walter Espriella castellar

Programa:

Ingeniería de sistemas VIII semestre

Sección: 1º

FUNDACION UNIVERSITARIA TECNOLÓGICO COMFENALCO CARTAGENA

30-09- 2026

INFORME FINAL: Minería de Texto

Obra: *The Mystery of the Blue Train* (El misterio del tren azul) - Agatha Christie

1. Documentación y Justificación de Limpieza (Fase de Pre-procesamiento) Para garantizar que el análisis estadístico fuera preciso, se aplicaron las siguientes transformaciones al texto bruto:


- **Conversión a minúsculas:** Se realizó para evitar que R contabilizara, por ejemplo, "Train" y "train" como dos palabras distintas.
- **Eliminación de puntuación y números:** Se suprimieron comas, puntos y cifras, ya que son caracteres estructurales que carecen de valor semántico para entender la trama.
- **Eliminación de Stopwords (Palabras vacías):** Utilizando el paquete tm, se eliminaron artículos, preposiciones y conectores en inglés (ej. *the, and, of*). Esta limpieza es fundamental porque, aunque son las palabras más repetidas, no aportan ninguna información sobre los personajes, la acción o los lugares de la novela. Tras este paso, el texto pasó de 71,762 palabras brutas a 33,754 palabras con valor analítico.

2. Análisis de las 5 palabras predominantes


- **1. Palabra:** said (Dijo/Dicho) | **Frecuencia:** 818 | **Porcentaje:** 2.42%
 - **Relación:** Al ser la palabra más usada, demuestra que el estilo narrativo de Agatha Christie se basa fundamentalmente en el diálogo, las entrevistas y los interrogatorios, algo típico y necesario en novelas de detectives para avanzar la trama.
- **2. Palabra:** poirot | **Frecuencia:** 499 | **Porcentaje:** 1.48%
 - **Relación:** Es el detective protagonista (Hercule Poirot). Su altísima frecuencia confirma que él es el centro absoluto de la narrativa y quien lidera la investigación.
- **3. Palabra:** katherine | **Frecuencia:** 308 | **Porcentaje:** 0.91%
 - **Relación:** Katherine Grey es uno de los personajes principales que viaja en el tren, lo que indica su relevancia constante en la historia acompañando al detective.
- **4. Palabra:** aldin | **Frecuencia:** 293 | **Porcentaje:** 0.87%
 - **Relación:** Rufus Aldin (el millonario) es un eje central, ya que es quien compra los famosos rubíes que desencadenan el misterio y el asesinato.

- **5. Palabra:** kettering | **Frecuencia:** 218 | **Porcentaje:** 0.65%
 - **Relación:** Es el apellido de casada de la víctima (Ruth Kettering). Su constante mención refleja que el caso gira todo el tiempo en torno a ella y a los motivos de su esposo (Derek Kettering).

Top 20 Palabras más Frecuentes - El Misterio del Tren Azul



Top 40 Palabras más Frecuentes - El Misterio del Tren Azul



3. Respuesta a las preguntas de análisis

1.  **¿Cuál es la palabra con mayor frecuencia?** La palabra más frecuente es "said" con 818 apariciones.
2.  **¿Cuáles son las cinco palabras más frecuentes?** Son: *said, poirot, one, katherine, aldin*.
3.  **¿Qué porcentaje representan las palabras principales?** La palabra principal ("said") representa el 2.42% del texto útil. Si sumamos el TOP 5 completo, representan aproximadamente el 6.62% de todas las palabras filtradas del libro.
4.  **¿Aparecen nombres de personajes entre los términos más frecuentes?** Sí, dominan absolutamente la tabla. Aparecen claramente *Poirot, Katherine, Aldin* y *Kettering* dentro del TOP 10, lo que nos permite mapear a los protagonistas sin haber leído la obra.
5.  **¿Aparecen lugares relevantes?** Sí, revisando el texto, conceptos como *train* (tren) o *van* (usado en apellidos de sospechosos o en la palabra vagón) se ubican muy alto en la frecuencia, lo que enmarca espacialmente la historia.
6.  **¿Qué conceptos se repiten con mayor frecuencia?** Conceptos de acción declarativa ("said") y de conocimiento/deducción como "know" (saber), que aparece 211 veces en el puesto 10, evidenciando el enfoque lógico y de descubrimiento del misterio.
7.  **¿Qué relación existe entre las palabras predominantes y el contenido?** Existe una relación directa. Las palabras filtradas arman el esqueleto perfecto de la novela: un detective (Poirot) resolviendo un caso vinculado a una familia (Kettering/Aldin) a través de interrogatorios y diálogos constantes (*said, know*).
8.  **¿Qué información puede obtenerse mediante la minería de texto?** Se puede obtener la estructura narrativa de la novela, la red de jerarquía de personajes según su frecuencia de mención y el estilo literario del autor de manera puramente cuantitativa.

4. Conclusión y Reflexión Final

Mediante estas técnicas de minería de texto, pudimos descubrir la estructura subyacente de la novela de Agatha Christie de una forma que la lectura tradicional no permite. Sin necesidad de leer las cientos de páginas del libro, el algoritmo nos demostró con datos matemáticos que la autora sostiene su misterio principalmente a través del diálogo (comprobado por la aplastante frecuencia del verbo 'said'). Además, nos permitió identificar al instante quiénes son los sospechosos y protagonistas más relevantes, así como el núcleo de la obra, basándonos puramente en estadística y no en intuición.

